

# Đồ Thị Tính Toán

Bùi Tiến Lên



KHOA CÔNG NGHỆ THÔNG TIN  
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

# Biểu thức và Tính toán

---

- Xét biểu thức

$$e \leftarrow (a + b) \times (b + 1)$$

- Chuyển biểu thức thành các biểu thức *đơn*

1.  $a \leftarrow ?$

2.  $b \leftarrow ?$

3.  $c \leftarrow a + b$

4.  $d \leftarrow b + 1$

5.  $e \leftarrow c \times d$

- Viết một **hàm** tính toán

# Nhận xét

---

- Cài đặt nhanh và dễ hiểu
- Tuy nhiên, nếu biểu thức có rất nhiều biến, được sử dụng nhiều lần và với các mục đích khác thì cách biểu diễn như vậy chưa hiệu quả

# Đồ thị tính toán


---

- Đồ thị tính toán (**computational graph**) là cấu trúc dữ liệu đồ thị DAG (**directed acyclic graph**) biểu diễn một mô hình tính toán (ví dụ, mạng nơ-ron, mạng Bayes).
- Đồ thị tính toán được cài đặt sẵn trong các thư viện TensorFlow, PyTorch .v.v.

# BIỂU DIỄN VÀ TÍNH TOÁN

# Biểu diễn

---



Input Layer  $\in \mathbb{R}^4$

Hidden Layer  $\in \mathbb{R}^{10}$

Hidden Layer  $\in \mathbb{R}^8$

Output Layer  $\in \mathbb{R}^3$

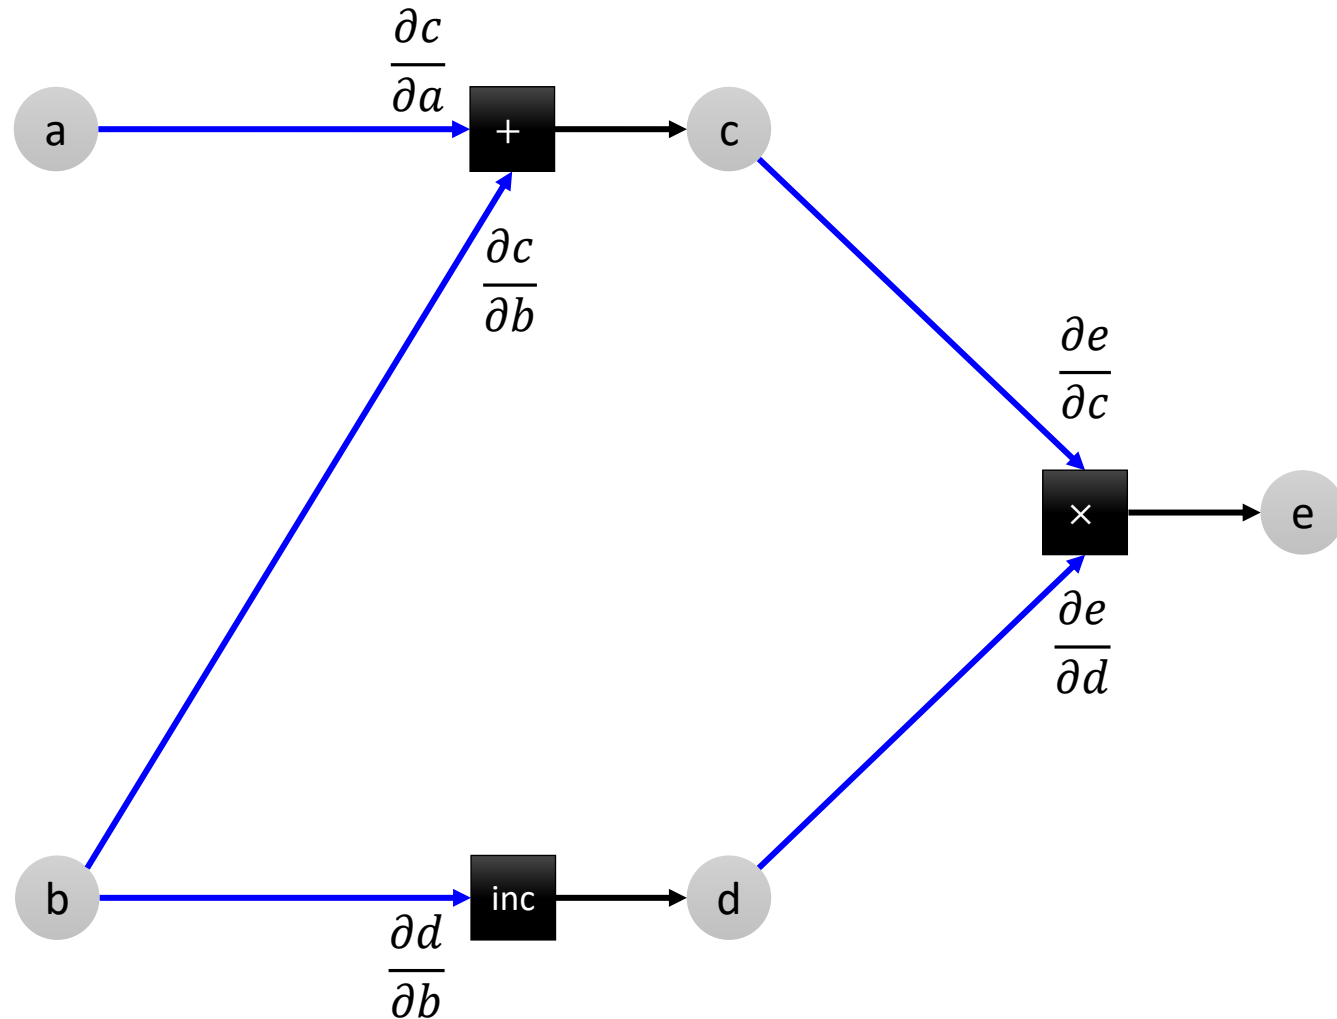
# Cấu trúc

---

- Mỗi đỉnh
  - Tương ứng với một *biến* (**variable**) hoặc *tham số* (**parameter**)
  - Tương ứng với một *hàm, phép toán, cổng* (**function, operator, gate**)
- Các cạnh có hướng nối *đỉnh biến* với *đỉnh phép toán*
- Cấu trúc đồ thị dùng để tính toán giá trị các biến và *đạo hàm* (**gradient**)

# Xây dựng đồ thị tính toán đầy đủ

- $a \leftarrow ?$
- $b \leftarrow ?$
- $c \leftarrow a + b$
- $d \leftarrow b + 1$
- $e \leftarrow c \times d$





# Đồ thị tính toán rút gọn

- Rút gọn đỉnh **gate**

- Đỉnh

$a, b, c, d, e$

- Cạnh


$a \rightarrow c$

$b \rightarrow c$

$b \rightarrow d$

$c \rightarrow e$


$d \rightarrow e$



# Đồ thị tính toán rút gọn

**Đỉnh biến** thành **cạnh biến**

- $a \leftarrow ?$
- $b \leftarrow ?$
- $c \leftarrow a + b$
- $d \leftarrow b + 1$
- $e \leftarrow c \times d$



# Một số công thức tính đạo hàm

---

$$f(x) = f_1(x) + f_2(x)$$

$$\frac{\partial f}{\partial x} = \frac{\partial f_1}{\partial x} + \frac{\partial f_2}{\partial x}$$

$$f(x) = f_1(x) - f_2(x)$$

$$\frac{\partial f}{\partial x} = \frac{\partial f_1}{\partial x} - \frac{\partial f_2}{\partial x}$$

$$f(x) = f_1(x) \cdot f_2(x)$$

$$\frac{\partial f}{\partial x} = f_2 \frac{\partial f_1}{\partial x} + f_1 \frac{\partial f_2}{\partial x}$$

$$f(x) = \frac{f_1(x)}{f_2(x)}$$

$$\frac{\partial f}{\partial x} = \frac{1}{f_2} \frac{\partial f_1}{\partial x} - \frac{f_1}{f_2^2} \frac{\partial f_2}{\partial x}$$

$$f(g(x))$$

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial g} \frac{\partial g}{\partial x}$$

(chain rule)

# Một số công thức tính đạo hàm

---

$$y = x^n \qquad \frac{\partial y}{\partial x} = n \cdot x^{n-1}$$

$$y = \exp(x) \qquad \frac{\partial y}{\partial x} = \exp(x) \qquad y = \log(x) \qquad \frac{\partial y}{\partial x} = \frac{1}{x}$$

hoặc

$$\frac{\partial y}{\partial x} = y$$

$$y = \sigma(x) = \frac{1}{1 + \exp(-x)} \qquad \frac{\partial y}{\partial x} = \frac{\exp(-x)}{(1 + \exp(-x))^2} \qquad y = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \qquad \frac{\partial y}{\partial x} = 1 - y^2$$

hoặc

$$\frac{\partial y}{\partial x} = y(1 - y)$$

# Một số công thức tính đạo hàm

---



$$y = \sin(x) \quad \frac{\partial y}{\partial x} = \cos(x)$$

$$y = \cos(x) \quad \frac{\partial y}{\partial x} = -\sin(x)$$

$$y = \tan(x) \quad \frac{\partial y}{\partial x} = \frac{1}{\cos(x)^2}$$



# Tính toán

- Cho  $a = 2, b = 1$ , tính giá trị các biến và đạo hàm cực bộ



# Cập nhật

- Cập nhật  $a = 4$



# TÍNH ĐẠO HÀM TỪNG PHẦN



# Phương pháp tính đạo hàm/vi phân

---

- Phương pháp **đạo hàm số** (numerical differentiation)

$$\frac{\partial f(x_0)}{\partial x} \approx \frac{f(x_0 + h) - f(x_0)}{h} \approx 0.333$$

- Phương pháp **đạo hàm ký hiệu** (symbolic differentiation)

$$\cos(x)' = -\sin(x)$$

- Phương pháp **đạo hàm tự động** (automatic differentiation)

đạo hàm số + đạo hàm ký hiệu

# Phương pháp đạo hàm tự động

---

- Xét chuỗi quan hệ hàm giữa các biến  $x, y, z, w$


$$x \rightarrow y \rightarrow z \rightarrow w$$



# Phương pháp tiến

- Tính đạo hàm bằng phương pháp tiến (chain rule)


$$\frac{\partial w}{\partial x} = ? = \overrightarrow{\frac{\partial x}{\partial x} \frac{\partial y}{\partial x} \frac{\partial z}{\partial y} \frac{\partial w}{\partial z}}$$



# Phương pháp lùi

- Tính đạo hàm bằng phương pháp lùi (chain rule)


$$\frac{\partial w}{\partial x} = ? = \frac{\partial y}{\partial x} \frac{\partial z}{\partial y} \frac{\partial w}{\partial z} \frac{\partial w}{\partial w}$$



# Phương pháp tổng

---

- Tính tổng các đường đi đạo hàm




$$\frac{\partial y}{\partial x} = \sum_{i=1}^n \frac{\partial^{(i)}y}{\partial x}$$

# Phương pháp tổng (cont.)

---

- Tính tổng các đường đi (9 đường)




$$\frac{\partial z}{\partial x} = \alpha_1\beta_1 + \alpha_1\beta_2 + \alpha_1\beta_3 + \alpha_2\beta_1 + \alpha_2\beta_2 + \alpha_2\beta_3 + \alpha_3\beta_1 + \alpha_3\beta_2 + \alpha_3\beta_3$$

# Phương pháp tổng (cont.)

---

- Tính tổng đường đi từng chặng (2 chặng – mỗi chặng 3 đường)



$$\frac{\partial x}{\partial x} = 1$$

$$\frac{\partial y}{\partial x} = \alpha_1 + \alpha_2 + \alpha_3$$


$$\frac{\partial z}{\partial x} = (\alpha_1 + \alpha_2 + \alpha_3)(\beta_1 + \beta_2 + \beta_3)$$

# VÍ DỤ TÍNH ĐẠO HÀM TỪNG PHẦN




# Đạo hàm tiến – ví dụ


- Cho đồ thị tính toán dưới, tính đạo hàm  $\frac{\partial e}{\partial b}$  tại  $a = 2, b = 1$



# Đạo hàm tiến – tính toán




# Đạo hàm tiến – tính đạo hàm




# Đạo hàm lùi – ví dụ

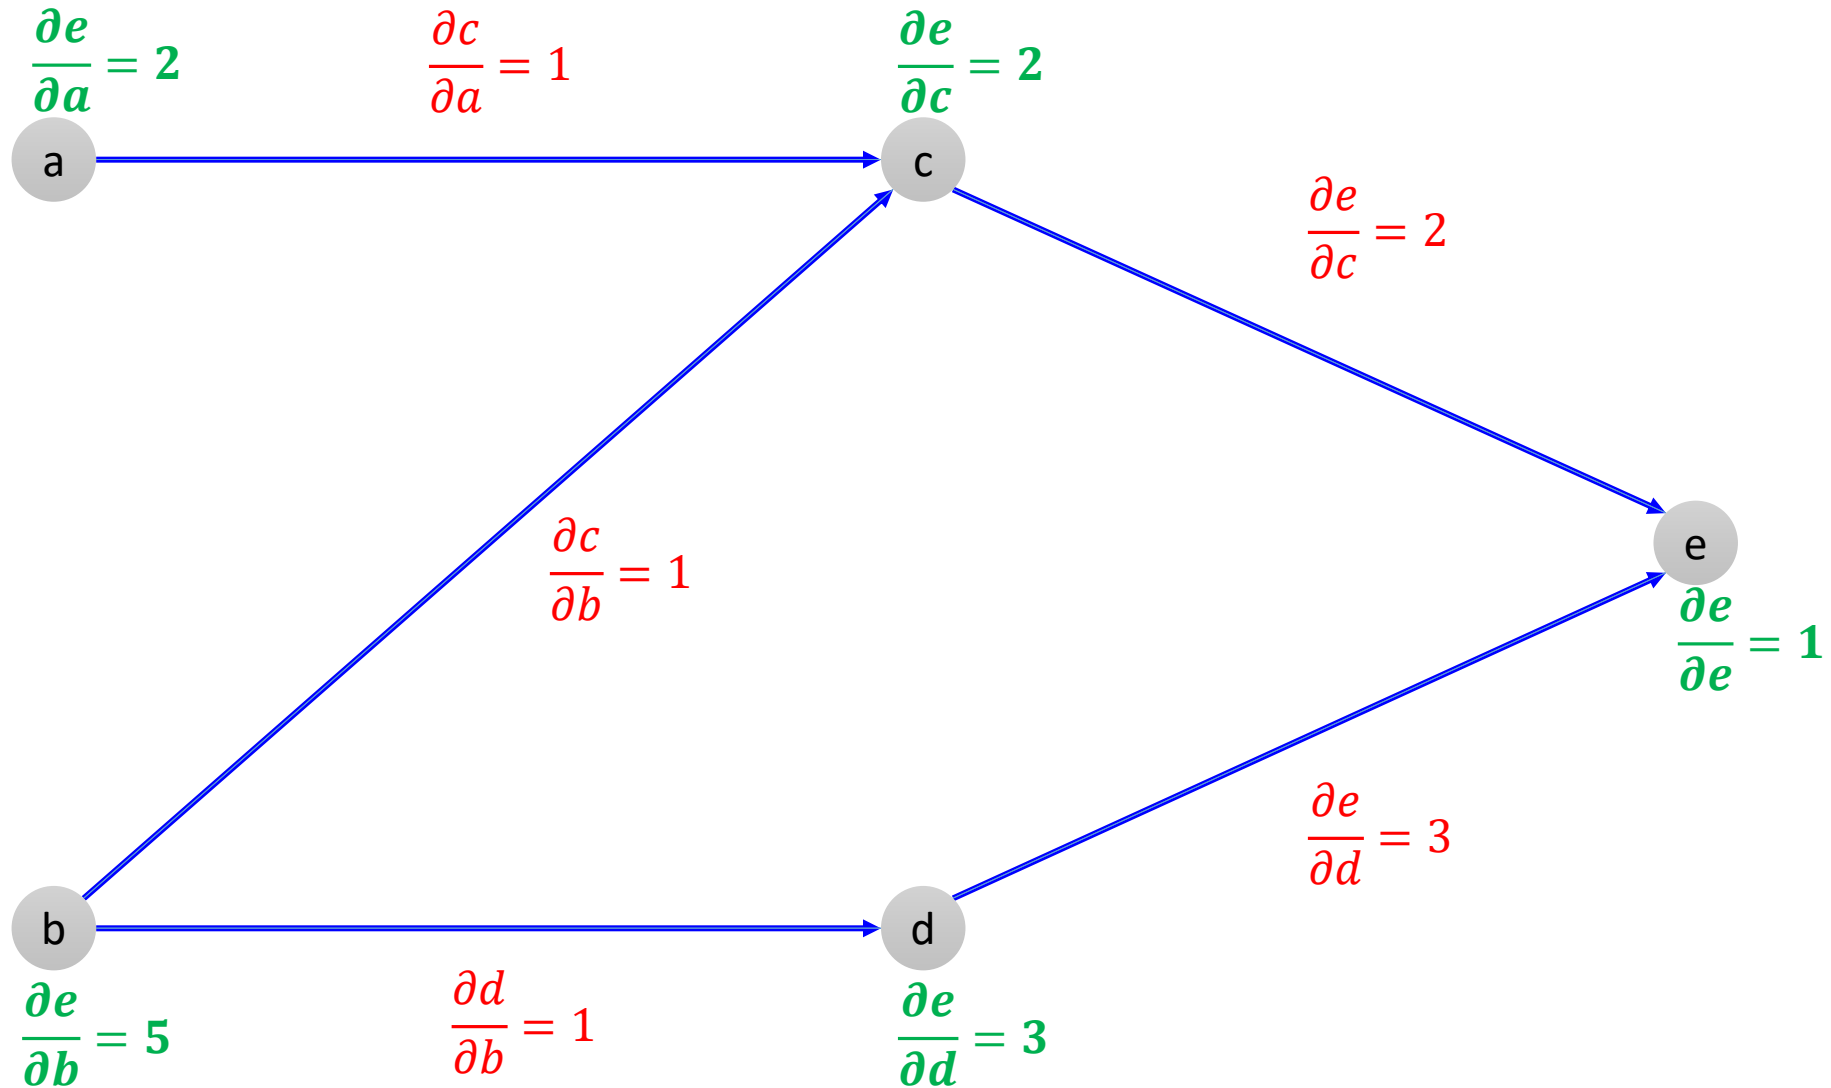
- Cho đồ thị tính toán dưới, tính đạo hàm  $\frac{\partial e}{\partial b}$ ,  $\frac{\partial e}{\partial a}$  tại  $a = 2, b = 1$



# Đạo hàm lùi – tính toán




# Đạo hàm lùi – tính đạo hàm




# Một số mẫu trong tính toán đạo hàm lùi

- Xét một đồ thị tính toán **đầy đủ** cho biểu thức  $a = 2 \times (x \times y + \max(z, w))$



# Một số mẫu trong tính toán đạo hàm lùi (cont.)

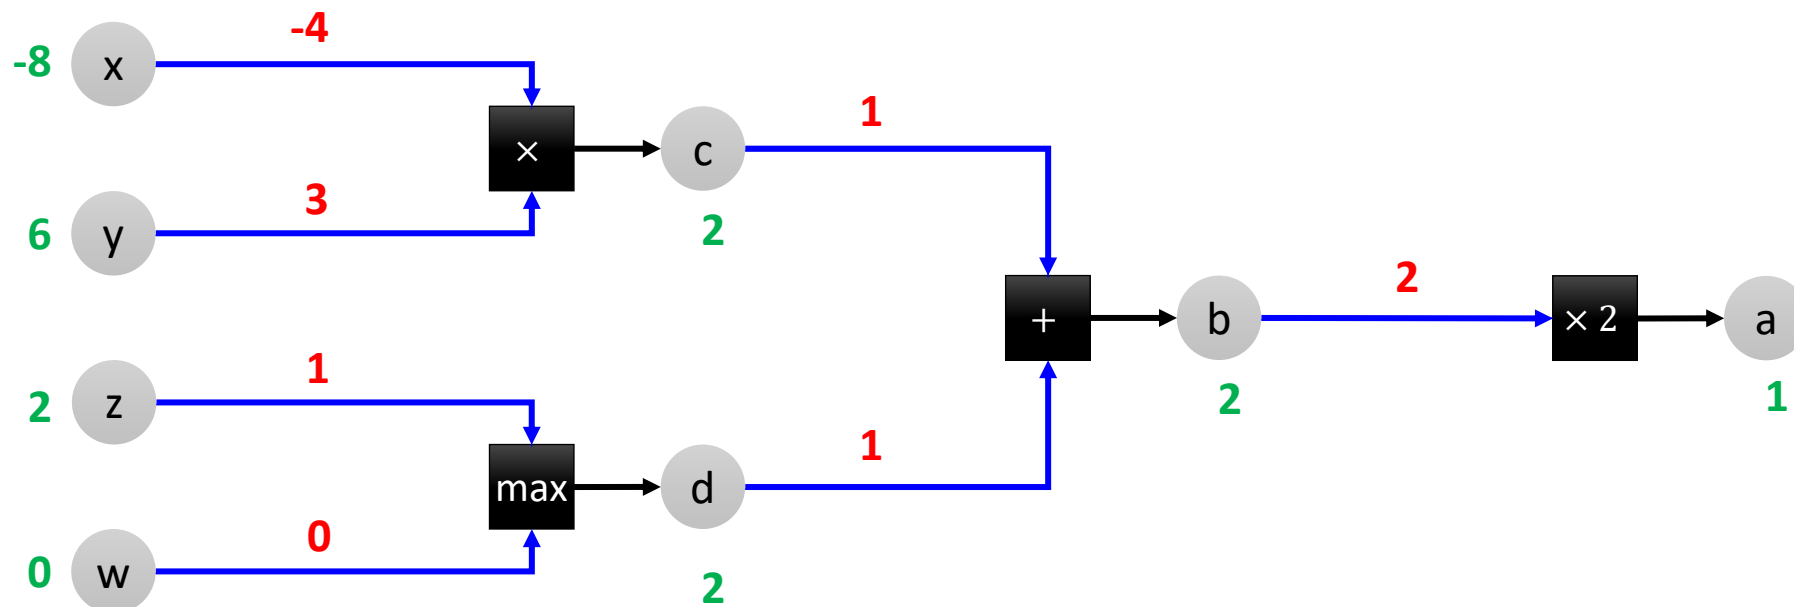
- Tính giá trị các biến và đạo hàm cục bộ  $x = 3, y = -4, z = 2, w = -1$





# Một số mẫu trong tính toán đạo hàm lùi (cont.)

- Tính đạo hàm riêng phần của biến  $a$  với các biến còn lại



Cổng **scale** ( $\times k$ ): khuếch đại luồng gradient

Cổng **add** ( $+$ ): phân phối luồng gradient

Cổng **mul** ( $\times$ ): chuyển đổi luồng gradient

Cổng **max**: định tuyến luồng gradient




# TÍNH TOÁN TRÊN TENSOR

# Tensor

---

Các biến, tham số được biểu diễn bằng tensor:

- Số (tensor 0 chiều)
- Vector (tensor 1 chiều)
- Ma trận (tensor 2 chiều)
- ...



# Các phép toán trên tensor


---

- Các phép toán element-wise
  - Cộng, trừ, nhân (Hadamard), chia, ...
  - Hàm: sigmoid ( $\sigma$ ), tanh, cos, sin, ...
  - ...
- Các phép toán không phải element-wise
  - Nhân ma trận với vector
  - Nhân ma trận với ma trận
  - ...


# Bài toán tính đạo hàm từng phần

**Giả định**  $L$  là biến **mất mát (loss)** đầu cuối của đồ thị tính toán.  $L$  là biến tensor 0 chiều. **Bài toán:** Tính đạo hàm từng phần (gradient)  $L$  với các biến tensor

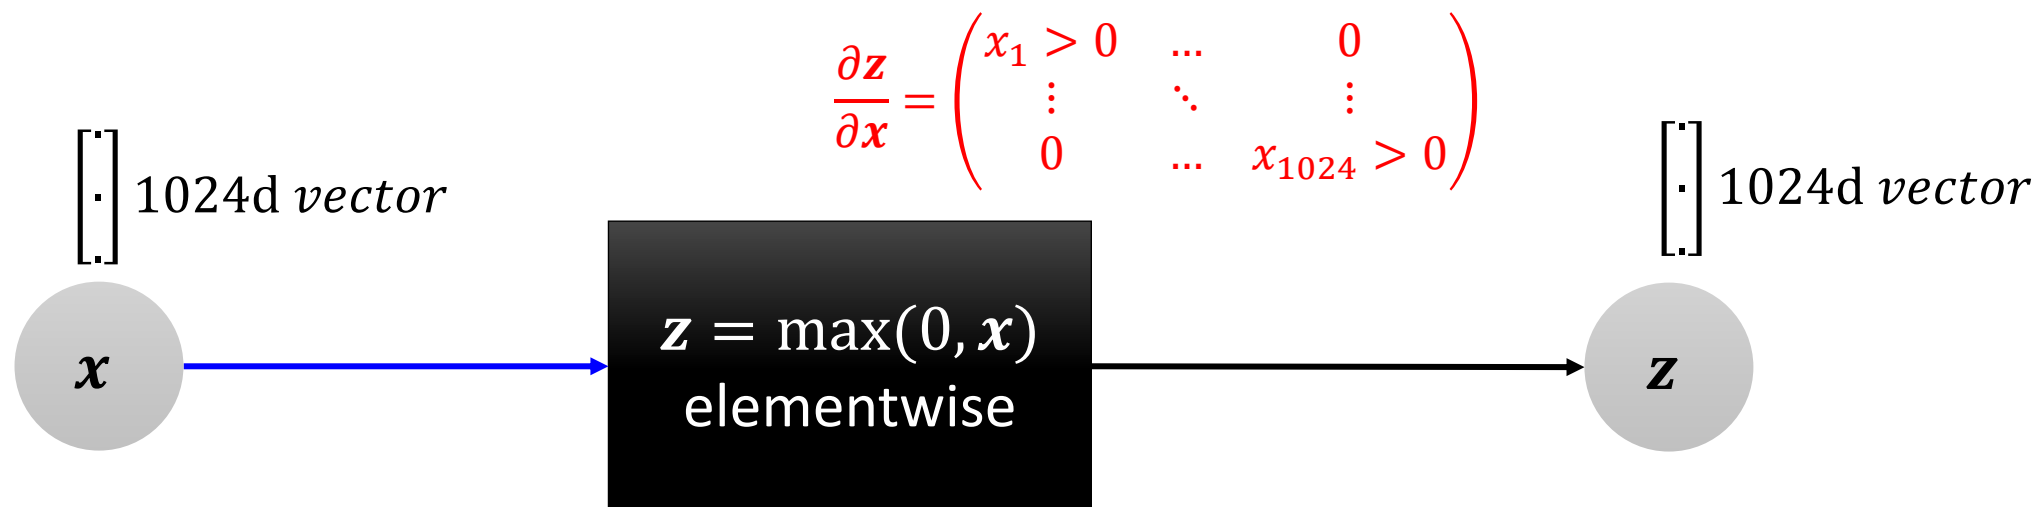
$$\frac{\partial L}{\partial x}$$



# Thử mở rộng nguyên tắc “nhân”



# Nhận xét



- Jacobian matrix có kích thước rất lớn  $1024 \times 1024$ , nhưng lại rất thưa
- Thực tế tính toán sẽ như thế nào?

# MỘT SỐ CÁCH TÍNH ĐẠO HÀM TỪNG PHẦN CHO MỘT SỐ PHÉP TOÁN



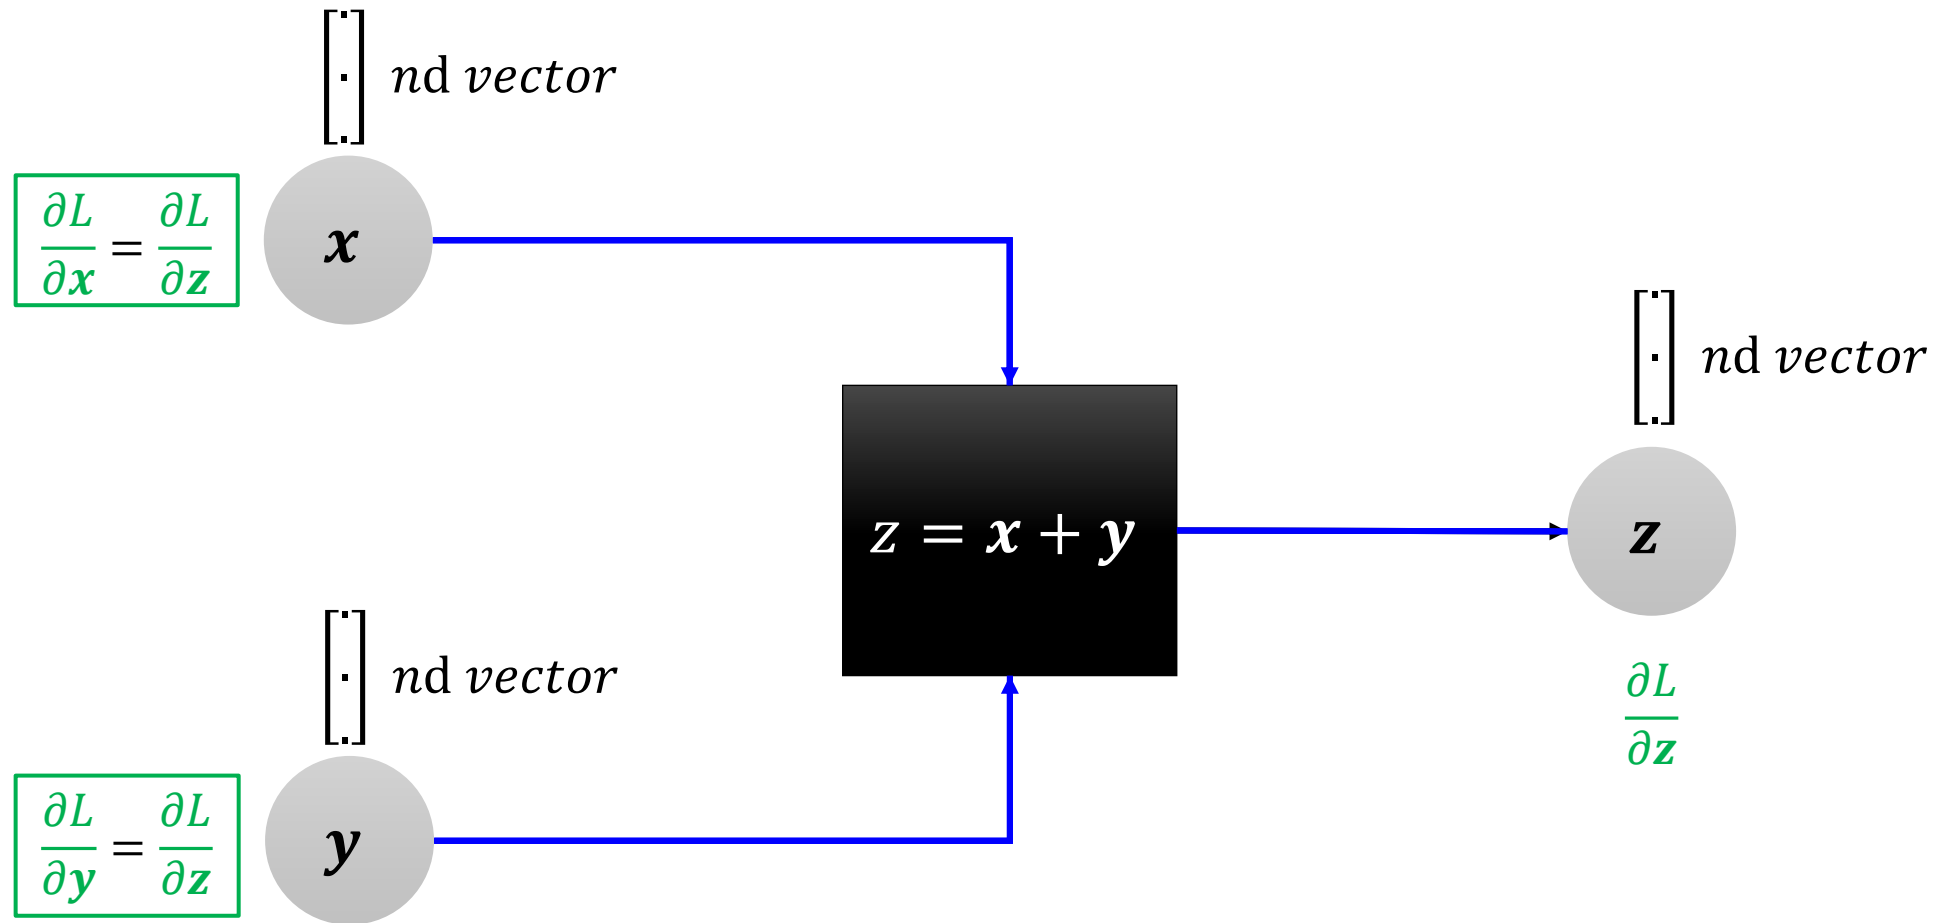
# Lưu ý chung

---

Khi tính đạo hàm từng phần của  $L$  đối với các biến tensor


- Sử dụng **phương pháp đạo hàm lùi**
- Nguyên tắc “nhân” **không còn đúng** do tính đa dạng của phép toán trên tensor
- Nguyên tắc cộng vẫn **đúng**

# Cộng phép cộng



# Cổng max (element-wise)

$$\begin{aligned} z_i &= \max(0, x_i) \\ \mathbf{z} &= \max(0, \mathbf{x}) \end{aligned}$$




$$\begin{aligned} \frac{\partial L}{\partial x_i} &= \begin{cases} \frac{\partial L}{\partial z_i} & x_i > 0 \\ 0 & x_i \leq 0 \end{cases} \\ \frac{\partial L}{\partial x} &= \max\left(0, \frac{\partial L}{\partial z}\right) \end{aligned}$$

# Cổng sigmoid (element-wise)

$$\mathbf{z} = \sigma(\mathbf{x})$$

$$\frac{\partial L}{\partial \mathbf{x}} = (1 - \mathbf{z})\mathbf{z} \frac{\partial L}{\partial \mathbf{z}}$$

element wise multiplication



# Cổng $L_2$


$$z = L_2(x) = \sum_{i=1}^n x_i^2$$

**Lưu ý:** có thể mở rộng phép toán  $L_2$  cho tensor bất kỳ

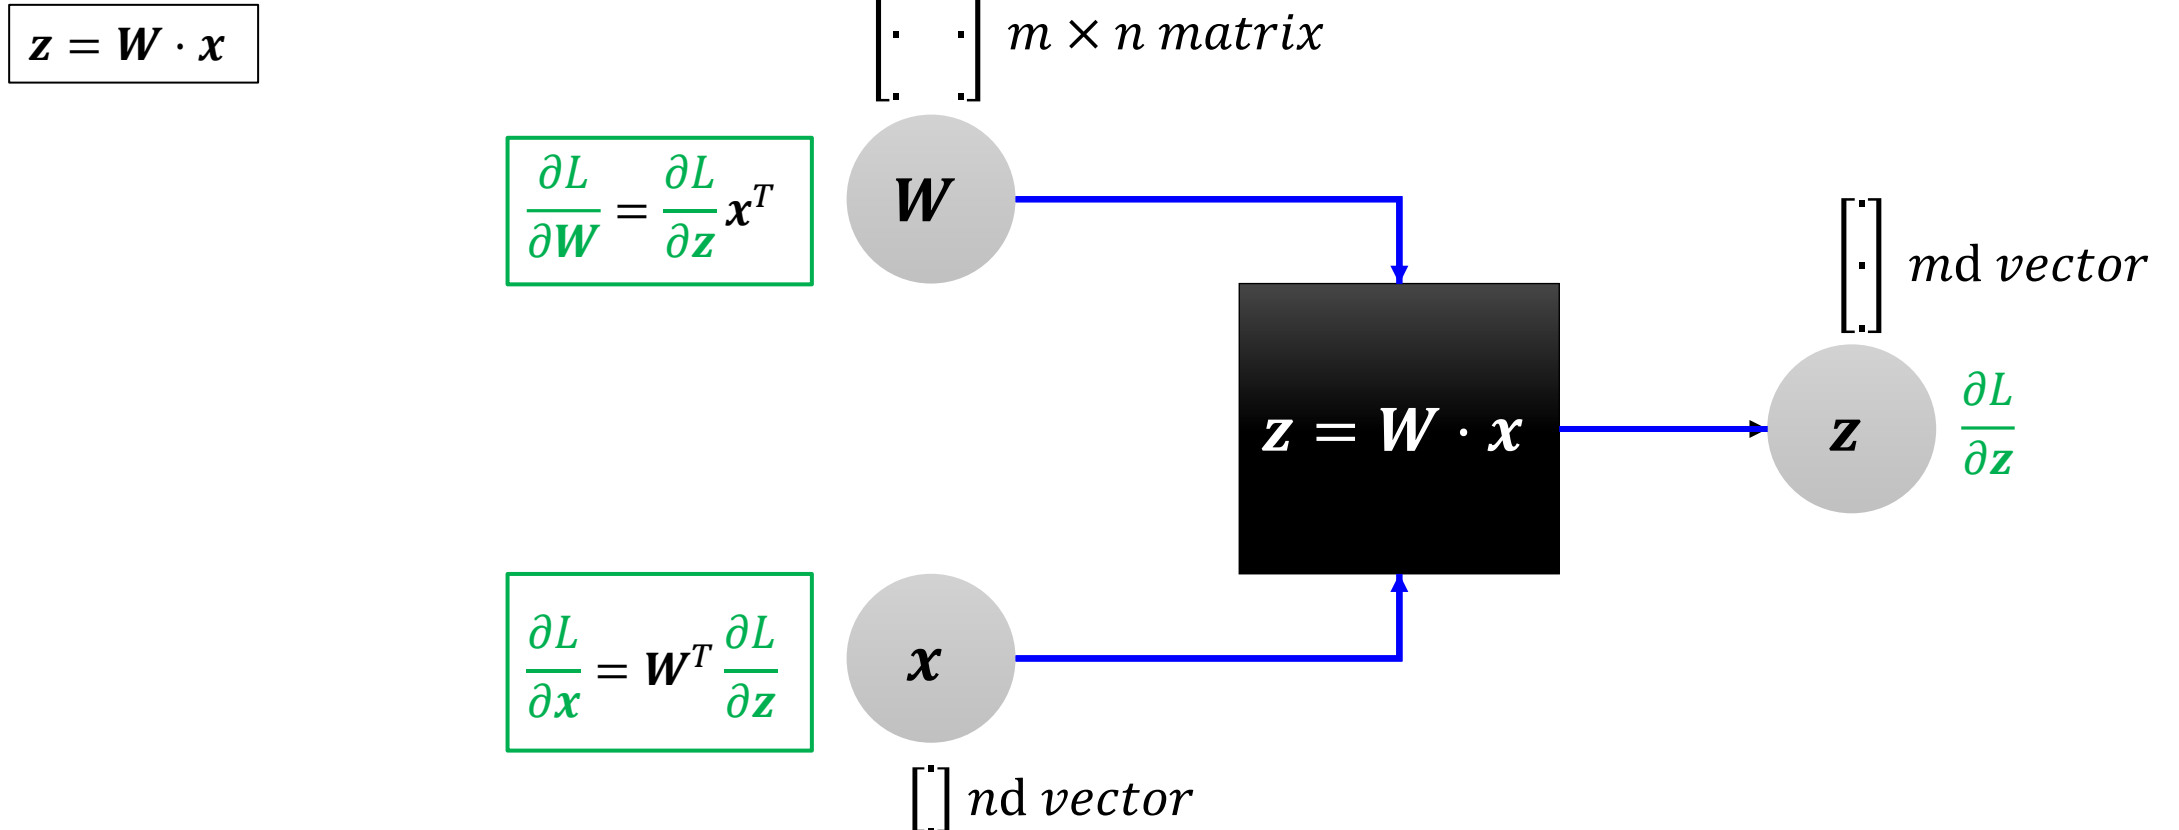
$$\frac{\partial z}{\partial x_i} = 2x_i$$

$$\frac{\partial L}{\partial x_i} = 2x_i \frac{\partial L}{\partial z}$$

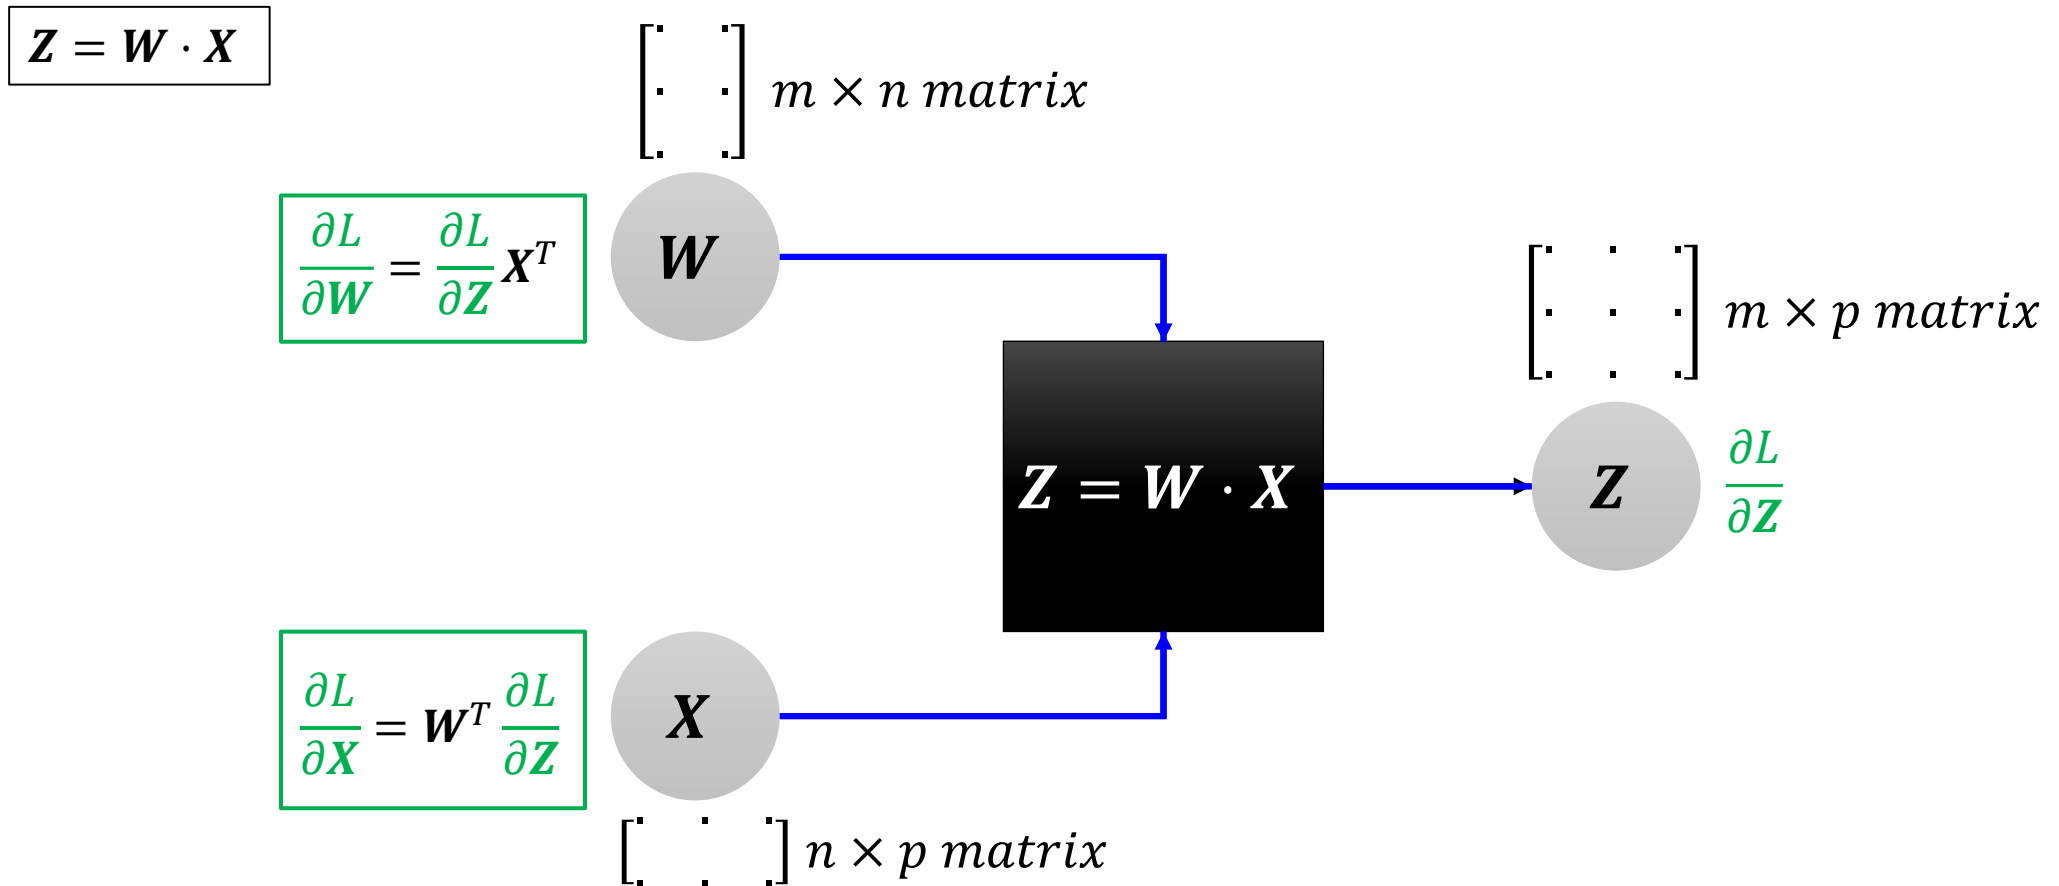
$$\frac{\partial L}{\partial x} = 2x \frac{\partial L}{\partial z}$$



# Cộng nhân ma trận và vector



# Cộng nhân ma trận và ma trận




# Cổng softmax

$$p_i = \frac{e^{z_i}}{\sum_{k=1}^n e^{z_k}}$$

$$\frac{\partial p_i}{\partial z_i} = p_i (1 - p_i)$$

và

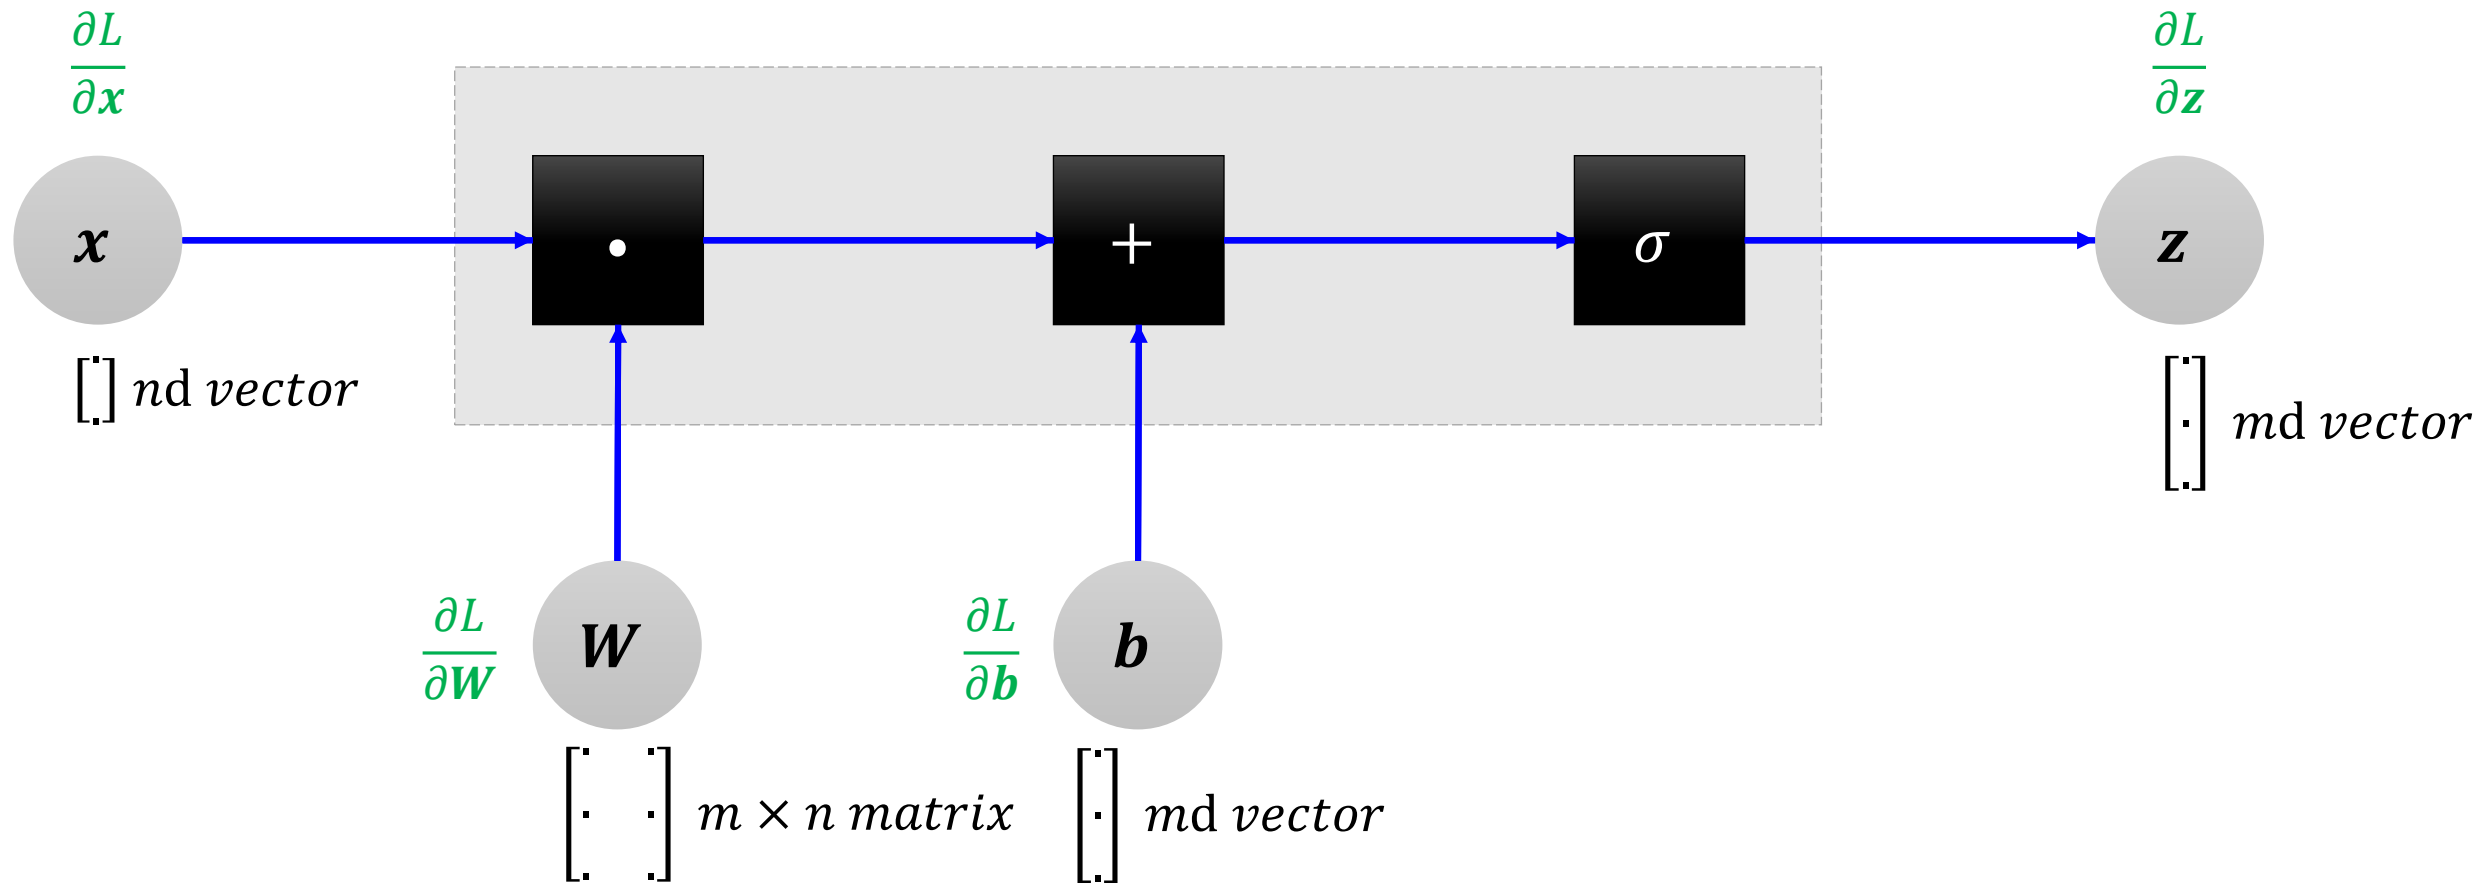
$$\frac{\partial p_j}{\partial z_i} = -p_i p_j, i \neq j$$



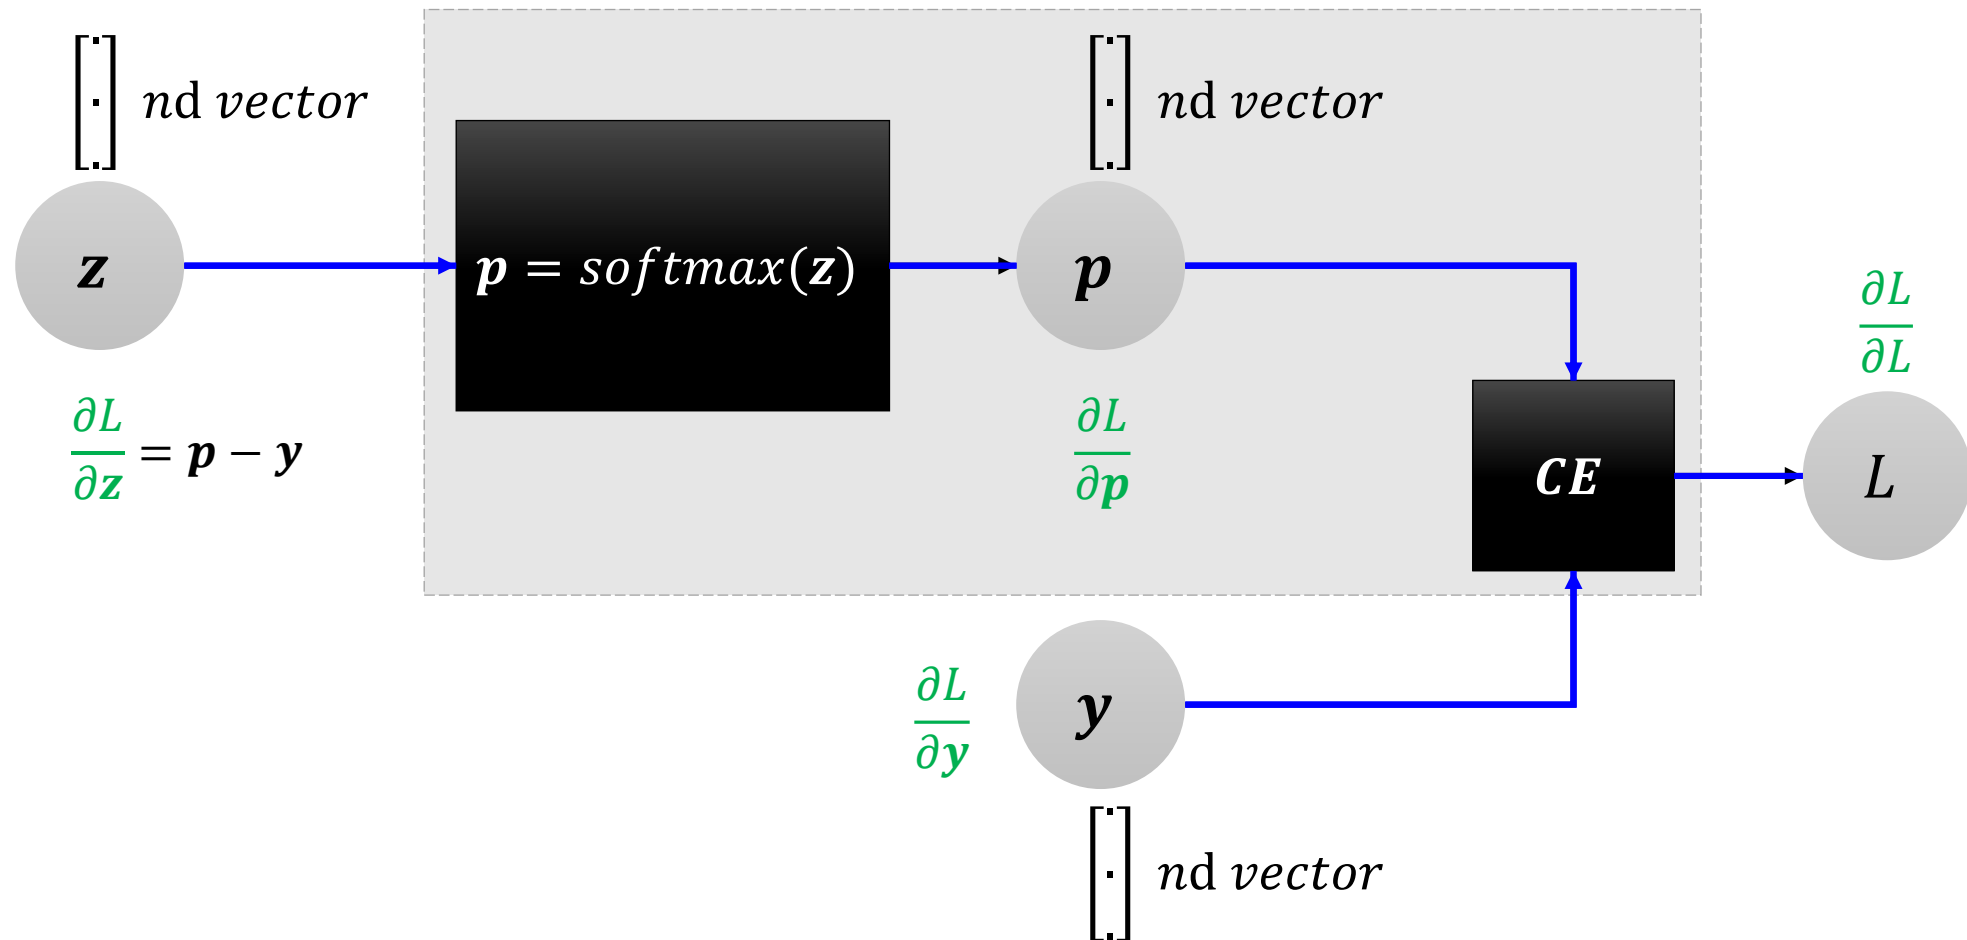


# TÍNH ĐẠO HÀM TỪNG PHẦN CHO KHỐI PHÉP TOÁN

# Khối MLP

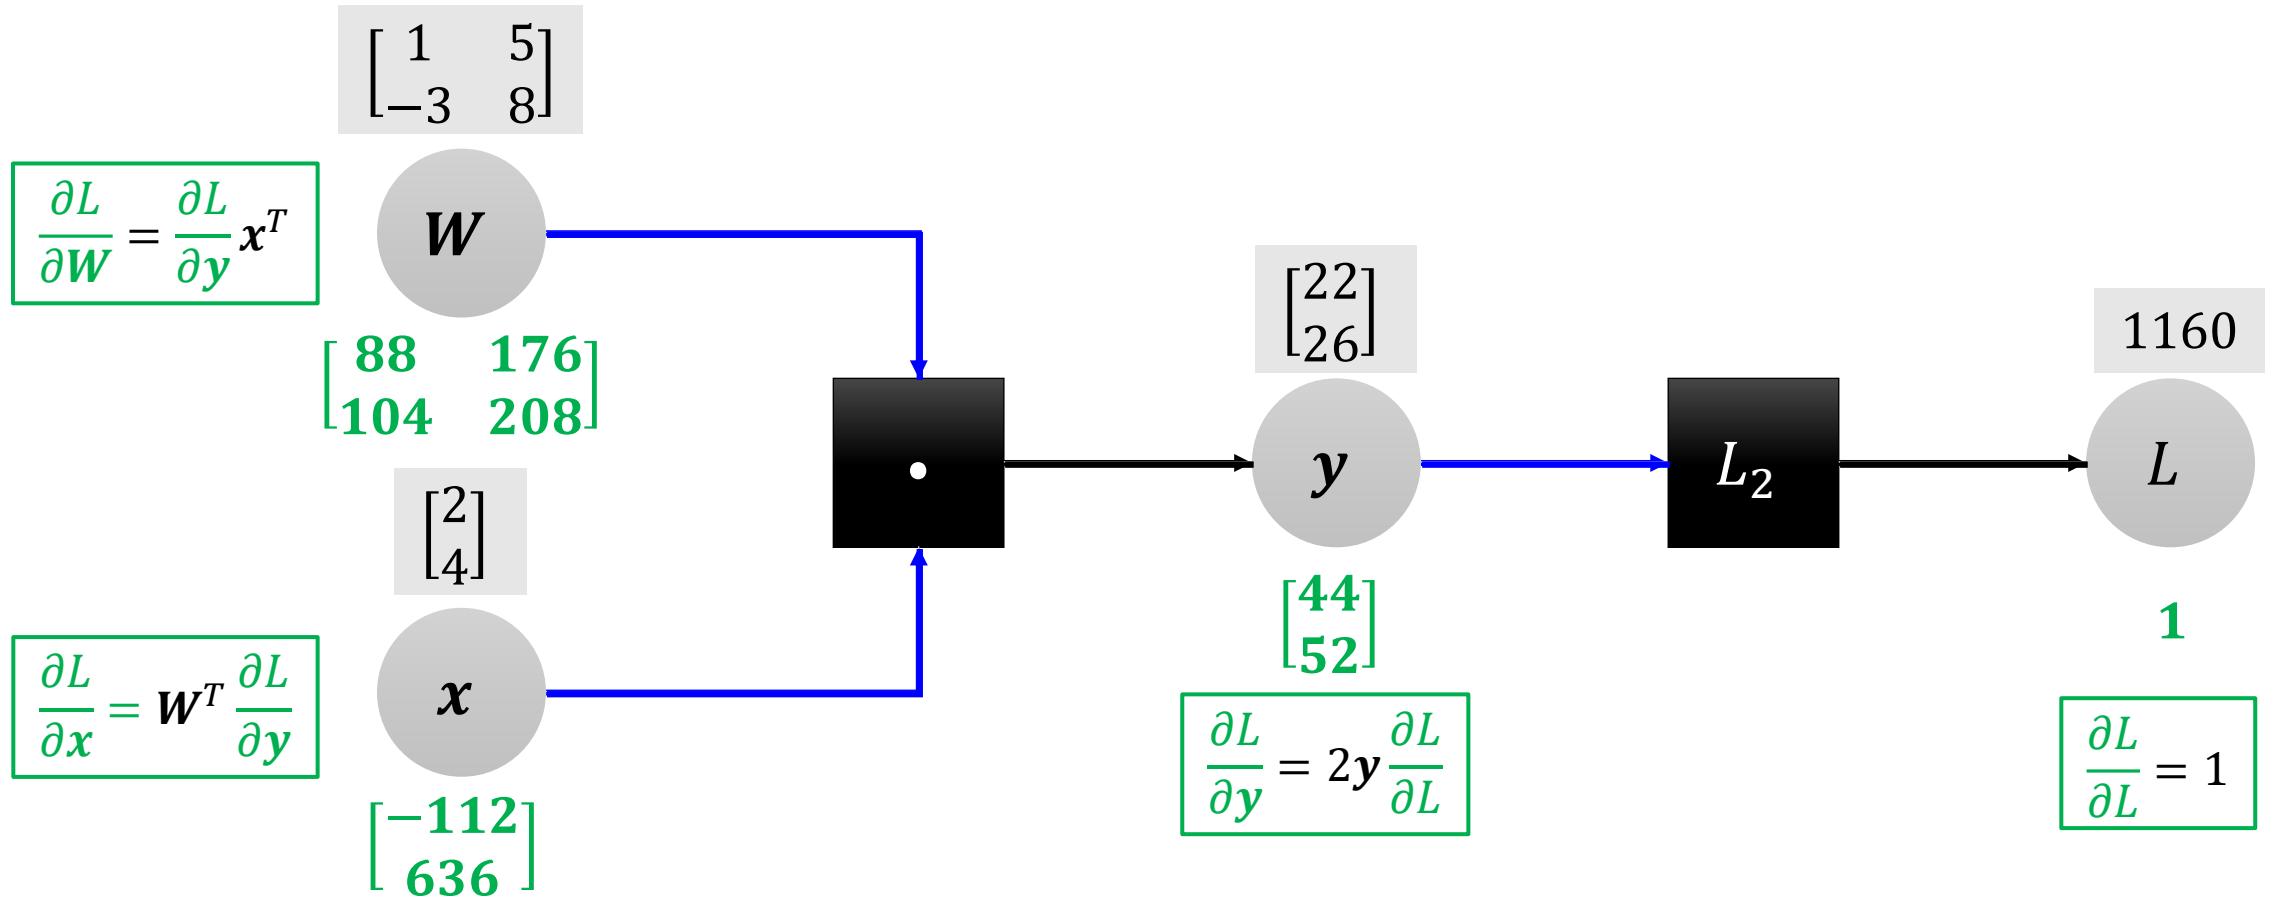


# Khối softmax + cross-entropy (CE)





# Ví dụ

- Cho một đồ thị tính toán của hàm  $L = L_2(\mathbf{W} \cdot \mathbf{x})$



**CÀI ĐẶT**

# Cài đặt API: forward/backward

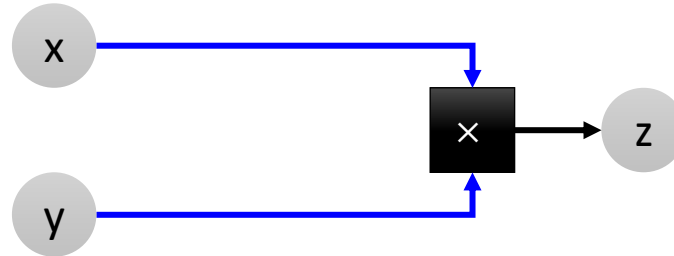


```
class ComputationalGraph:
    # ...
    def forward(self, inputs):
        # 1. pass inputs to gates ...
        # 2. forward the computational graph
        for gate in self.graph.nodes_topologically_sorted():
            gate.forward()
        return loss # the final gate in the graph outputs the loss

    def backward(self):
        for gate in reversed(self.graph.nodes_topologically_sorted()):
            gate.backward()
        return inputs_gradients
```

# Cài đặt API: forward/backward

---



```
class MultiplyGate:
    def forward(x, y):
        z = x * y
        self.dzdx = y # local gradient
        self.dzdy = x # local gradient
        return z
    def backward(dz): # upstream gradient
        dx = self.dzdx * dz
        dy = self.dzdy * dz
        return [dx, dy]
```

# BÀI TẬP




# Bài tập 1

- Xét biểu thức và tính đạo hàm từng phần của  $z$  với các biến tại  $x = \frac{\pi}{4}, y = 4$

$$z = x \cdot y + \sin(x)$$

- Phân tích biểu thức và vẽ

- $x \leftarrow ?$
- $y \leftarrow ?$
- $a \leftarrow x \cdot y$
- $b \leftarrow \sin(x)$
- $z \leftarrow a + b$



## Bài tập 2: logistic regression

---


- Xét biểu thức

$$f(\mathbf{x}, \mathbf{w}) = \frac{1}{1 + e^{-(w_0 + w_1 x_1 + w_2 x_2)}} = \sigma(w_0 + w_1 x_1 + w_2 x_2)$$

- Tính đạo hàm từng phần của  $f$  với các biến tại  $w_0 = -3, w_1 = 2, w_2 = -3, x_1 = -1, x_2 = -2$

## Bài tập 2: logistic regression

---



# Bài tập 3


---

- Xây dựng cách tính đạo hàm từng phần cho các cổng phép toán  $+$ ,  $-$ ,  $*$ ,  $/$  cho các tensor:

## Bài tập 4

---

- Xây dựng cách tính đạo hàm từng phần cho các cổng hàm (element-wise)  $\exp(\mathbf{x})$ ,  $\log(\mathbf{x})$ ,  $\cos(\mathbf{x})$ ,  $\sin(\mathbf{x})$ ,  $\text{ReLU}(\mathbf{x})$ :



# Bài tập lập trình

---

Xây dựng và huấn luyện các mạng nơ-ron bằng dữ liệu Mnist với các kiến trúc sau.

- 2 lớp  $y = W \cdot x + b$
- 3 lớp  $y = W_2 \cdot \text{ReLU}(W_1 \cdot x + b_1) + b_2$
- 4 lớp  $y = W_3 \cdot \text{ReLU}(W_2 \cdot \text{ReLU}(W_1 \cdot x + b_1) + b_2) + b_3$

# Tài liệu tham khảo

---

- Calculus on Computational Graphs: Backpropagation

<https://colah.github.io/posts/2015-08-Backprop/>

- Lecture 4 of [Stanford 231n](#)